УНИВЕРЗИТЕТ У БЕОГРАДУ
МАТЕМАТИЧКИ ФАКУЛТЕТ

Зорана Гајић

САВРЕМЕНИ АЛАТИ ЗА ПРИКУПЉАЊЕ ПОДАТАКА СА ВЕБ СТРАНИЦА

мастер рад

Београд, 2023.

Ментор:

др Милена Вујошевић Јаничић, ванредни професор
Универзитет у Београду, Математички факултет

Чланови комисије:

др Ана Аничић, ванредни професор
University of Disneyland, Недођија

др Лаза Лазић, доцент
Универзитет у Београду, Математички факултет

Датум одбране: 15. јануар 2016.

Породици

Наслов мастер рада: Савремени алати за прикупљање података са Веб страница

Резиме:

Кључне речи: прикупљање података са веб страница

Садржај

Глава 1

Увод

TODO:

Глава 2

Прикупљање података са Веб страница

TODO: Шта означава, процес у глобалу - прикупљање, издвајање и трансформација података, АПИ стругање, разлика између Веб и АПИ стругања

2.1 Изазови

TODO: Ботови,CAPTCHA, добијање забране, ИП блокирање, Honeypot замке, динамичан садржај, захтевање пријаве, смернице како избећи блокаде са сајтова

2.2 Примењене технологије

TODO: (HTML, Regex, XPath, Тагови, CSS Селектори)

Hyper Text Markup Language

TODO:

Regex

TODO:

XPath

TODO:

Тагови

TODO:

CSS Селектори

TODO:

Глава 3

Преглед алата за прикупљање података са Веб страница

TODO: Кратак увод шта ће се користити у поглављу, који програмски језик, које библиотеке, опис сајта, жељени циљеви, препреке са којима ћу се сусрести у раду

3.1 Библиотека BeautifulSoap

BeautifulSoap библиотека [6] представља једну од најједноставнијих за коришћење Пајтон библиотека за имплементацију прикупљања података из ХТМЛ и *КСМЛ* (енг. XML , Extensible Markup Language [1]) датотека преласком кроз *ДОМ* (енг. DOM, Document Object Model [2]). Искључиво ради само статичко прикупљање, које игнорише Јаваскрипт (енг. JavaScript), тј преузима се Веб страница са сервера без помоћи претраживача. За разлику од осталих библиотека које ће се касније у раду разматрати, ова библиотека не може сама да приступи Веб страници, већ јој је неопходна помоћна библиотека. Што значи да јој је главна функција парсирање ХТМЛ и КСМЛ датотека. Честа је пракса да се динамичан део Веб странице дохвати уз помоћ Selenium пакета [2], а да се парсирање података врши уз помоћ BeautifulSoap пакета.

[1] КСМЛ представља проширив (мета) језик за означавање (енгл. markup) текстуалних докумената. Више информација на `https://www.w3.org/TR/xml/`.

[2] ДОМ или објектни модел документа представља хијерархијски приказ структуре Веб сајта.

Инсталација

Неопходно је инсталирати *ПИП3* (енг. pip3 [3]) пакет менаџер и редом *BeautifulSoap*, *requests* [5] и парсер библиотеку *lxml* [3] уз помоћ наведених испод наредби.

```
pip3 install bs4
pip3 install requests
pip3 install lxml
```

Детаљно упутство за инсталацију се може пронаћи у званичној документацији BeautifulSoap библиотеке [6].

Провера динамичности Веб странице

Прва препрека коришћења BeautifulSoap пакета на примеру Киви Веб странице јесте та, да `https://www.kiwi.com/` представља динамичну страницу и да се без Јаваскрипта не може учитати. Самим тим не постоји могућност добијања података конкретно о летовима коришћењем искључиво BeautifulSoap пакета. Изглед Веб странице са угашеним Јаваскриптом је приказан на слици 3.1.

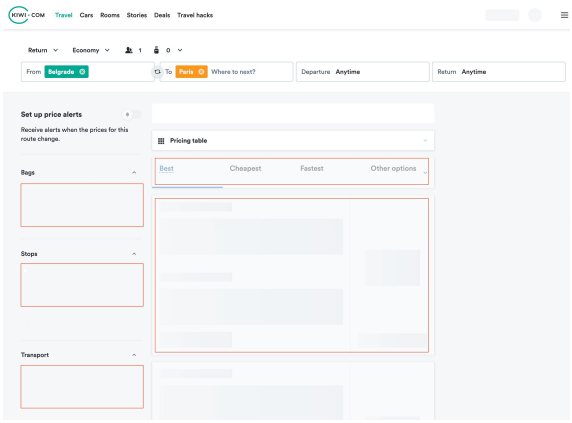

Слика 3.1: Киви веб сајт са угашеним Јаваскриптом

Да би се видело како конкретна Веб страница зависи од Јаваскрипта, у подешавању коришћеног претраживача је неопходно да се угаси опција коришћења Јаваскрипта и како то урадити на примеру *Хром* (енг. Google Chrome) претраживача је приказано на слици 3.2.

[3] `https://pip.pypa.io/en/stable/`

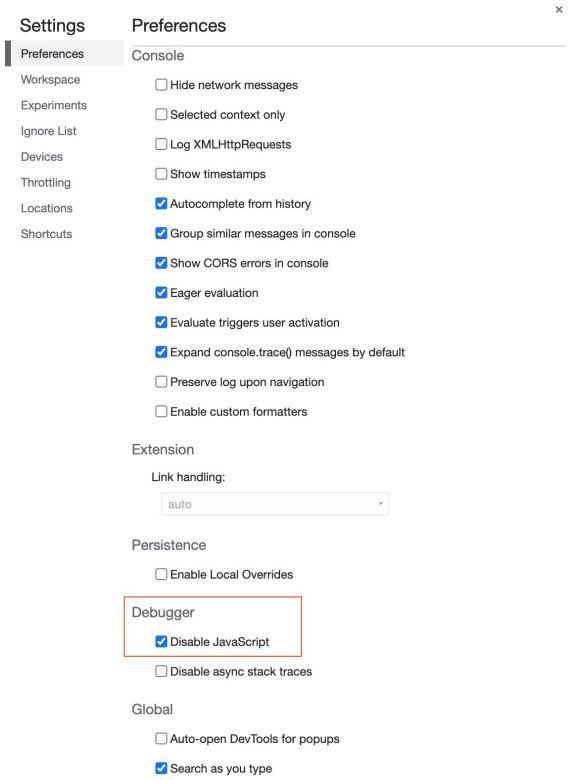

Слика 3.2: Подешавање претраживача

Прикупљање и парсирање ХТМЛ-а

BeautifulSoap није библиотека за скрејповање података са Веба сама по себи. То је библиотека која омогућава да се ефикасно и лако извуче информација из ХТМЛ-а.

Дакле, за почетак, потребан је ХТМЛ документ и у ту сврху се може искористити Пајтонов пакет *requests* који омогућава слање *ХТТП* (енг. HTTP, Hypertext Transfer Protocol [4]) захтева. Постоји неколико метода од значаја у овом пакету [4]:

- `get(url, params, args)`

  Шаље *ГЕТ* (енг. HTTP GET method) захтев на наведену веб адресу (енг. URL, Uniform Resource Locator))

- `post(url, data, json, args)`

[4]ХТТП је мрежни протокол који припада слоју апликације ОСИ референтног модела, представља главни и најчешћи метод преноса информација на вебу.

Шаље *ПОСТ* (енг. HTTP POST method) захтев на наведену веб адресу

- `put(url, data, args)`

  Шаље *ПУТ* (енг. HTTP PUT method) захтев на наведену веб адресу

У наставку је приказан код који преузима Веб страницу. Треба имати у виду да при преузимању странице са Веба, може да се догоди да страница не буде пронађена на серверу (или је дошло до грешке у њеном преузимању) или да сервер није пронађен.

```
1 import requests
2 from bs4 import BeautifulSoup
3
4 website = 'https://www.kiwi.com/en/search/results/belgrade-serbia/
    paris-france'
5 try:
6     response = requests.get(website)
7 except requests.exceptions.RequestException as err:
8     print("Error fetching page")
9     exit()
10
11 content = response.text
```

Даље, неопходно је испарсирати добијену ХТМЛ страницу тако што се креира *BeautifulSoap* конструктор који за параметре прихвата ХТМЛ страницу и парсер.

Пајтон нуди разне библиотеке за парсирање ХТМЛ-а, од којих су две најзаступљеније: *ЛКСМЛ* (енг. lxml [3]) и *ХТМЛ ɨарсер* (енг. html.parser [1]). Сваки пројекат има различите захтеве на основу којих се може одабрати најпогоднији парсер, па је за потребе овог рада одабран ЛКСМЛ парсер из једног простог разлога - брзина. ЛКСМЛ је најбржи парсер ХТМЛ страница према званичној документацији BeautifulSoap библиотеке [6]. Једна од мана овог парсера јесте екстерна зависност, али у овом случају то не представља проблем.

Наведени код ниже креира *BeautifulSoap* објекат, који омогућава лак приступ многим корисним информацијама, као што је наслов странице, сви линкови на страници, текст са странице...

```
1 soup = BeautifulSoup(content, 'lxml')
2
3 print(soup.title)
```

```
4 # <title>Belgrade-Paris trips</title>
5
6 print(soup.find_all('a'))
7 # [<a class="Logo__Link-sc-1uwlkrd-6 kcwlYu" data-test="Logo" href="/
      en/?destination=paris-france&amp;origin=belgrade-serbia">...]
8
9 print(soup.get_text())
10 # Belgrade Paris trips
11 # TravelCarsRoomsStoriesDealsTravel hacksloadingManage your trips, set
       up price alerts, use...
```

Циљање ДОМ елемената

У оквиру пакета BeautifulSoap постоје два метода која омогућавају једноставно и брзо филтрирање ХТМЛ странице за проналазак жељених информација [4]:

- `find(tag, attributes, recursive, text, keywords)`

  проналази и враћа жељени елемент, где су аргументи редом: назив тага или листа тагова, Пајтон речник атрибута и одговарајућих тагова које садрже било који од тих атрибута, булова вредност која представља да ли се претрага врши по глобалним таговима или и по унутрашњим таговима, подударност на основу текстуалног садржаја ознака, атрибут на основу којих се бира таг

- `findAll(tag, attributes, recursive, text, limit, keywords)`

  проналази и враћа листу жељених елемената, где су аргументи слични наведеним изнад са разликом што је додат аргумент лимит, који представља максималан број подударних елемената

Да би приказане информације биле занимљивије, ХТМЛ страница ће бити преузета коришћењем Selenium пакета из разлога што Selenium подржава Јаваскрипт. Детаљније о самом пакету Selenium може да се пронађе у наставку рада 3.2.

Одабрана је страница са летовима на релацији Београд-Малага `https://www.kiwi.com/en/search/results/belgrade-serbia/malaga-spain` и коришћењем Selenium пакета је направљен Пајтон скрипт који ће у одвојени фајл експортовати изворни ХТМЛ дате странице. У наставку је приказан код

који најпре затвара прозор за *колачиће* (енг. cookies [5]) који се отвара кад се приступи Веб страници, затим чека 10 секунди да би се страница учитала и цео изворни ХТМЛ експортује у одвојени фајл. И овим је решен проблем нединамичности пакета BeautifulSoap.

```
1 import time
2
3 from selenium import webdriver
4 from selenium.common import exceptions
5 from selenium.webdriver.chrome.service import Service
6 from selenium.webdriver.common.by import By
7
8 website = 'https://www.kiwi.com/en/search/results/belgrade-serbia/
      malaga-spain'
9 path = '/usr/local/bin/chromedriver_mac64/chromedriver'
10 service = Service(executable_path=path)
11 driver = webdriver.Chrome(service=service)
12 driver.get(website)
13 driver.maximize_window()
14
15 try:
16     # Close cookies dialog
17     cookie_dialog_close_btn = driver.find_element(By.XPATH, value=".//
      section[@id='cookie_consent']//button[@aria-label='Close']")
18     cookie_dialog_close_btn.click()
19
20     time.sleep(10)
21
22     with open('flights-belgrade-malaga-page-source.txt', 'w') as file:
23         file.write(driver.page_source)
24
25     driver.quit()
26
27 except exceptions.StaleElementReferenceException as e:
28     print(e)
29     pass
```

У наставку ће бити приказан комплетан код који извлачи информације из необрађеног ХТМЛ-а који је претходно био експортован у фајл: датум поласка, информације о одласку, датум повратка, информације о повратку,

[5]Колачић представља текстуалну датотеку која се чува у Веб прегледачу док корисник прегледа неку Веб страницу.

број ноћи, цена лета.

Најпре је неопходно установити како извући целе блокове са информацијама о лету. Када се детаљно прегледа структура ХТМЛ-а, може се приметити да је сваки лет издвојен у блок (енг. div [6]) са дугачким именом класе што представља једино по чему се тај блок може идентификовати. Пошто на страници има више летова, најпре се користи функција која проналази све инстанце по потпуној подударности имена класе. На исти начин се извршио проналазак броја ноћи касније. 3.3.

```
all_flights = soup.find_all('div', class_="
    ResultCardstyled__ResultCardInner-sc-vsw8q3-9 hlQpUC")
```

Осим потпуне подударности по имену класе, елемент се може пронаћи по свом јединственом *идентификатору* (енг. id [7]):

```
soup.find(id="specific_id")
```

Сада када су пронађени сви блокови са летовима, могу да се извуку информације о конкретно приказаном лету проласком кроз фор (енг. for) петљу кроз дате инстанце.

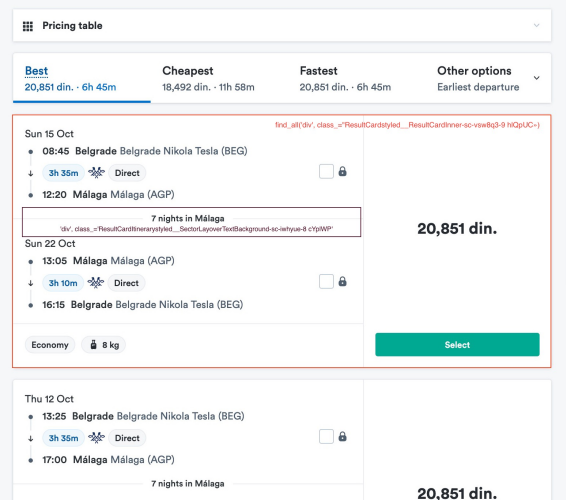

Слика 3.3: Комплетно поклапање класа

```
import re

import pandas as pd
```

[6] Ознака дефинише поделу или одељак у ХТМЛ документу.

[7] id атрибут се користи за одређивање јединственог идентификатора за ХТМЛ елемент.

```
4 from bs4 import BeautifulSoup
5
6 with open('flights-belgrade-malaga-page-source.txt', 'r') as file:
7     soup = BeautifulSoup(file, 'lxml')
8
9     all_flights = soup.find_all('div', class_="
    ResultCardstyled__ResultCardInner-sc-vsw8q3-9 hlQpUC")
10
11    departure_date_regex = re.compile('.*DepartureDate.*')
12    departure_info_regex = re.compile('.*
    ResultCardItineraryPlacestyled__StyledResultCardItineraryPlace.*')
13
14    flights = []
15    departure_dates = []
16    departure_info = []
17    return_dates = []
18    return_info = []
19    nights = []
20    prices = []
21
22    for flight in all_flights:
23        nights_spent = flight.find('div', class_='
    ResultCardItinerarystyled__SectorLayoverTextBackground-sc-iwhyue-8
    cYplWP').text.split(' ')[0]
24
25        dates = flight.find_all("p", {"class" : departure_date_regex})
26
27        departure_dates.append(dates[0].find('time').text)
28        return_dates.append(dates[1].find('time').text)
29
30        departure_time = flight.find_all('div',  {"class" :
    departure_info_regex})[0].find('time').text
31        departure_airport = flight.find_all('div',  {"class" :
    departure_info_regex})[0].find('div').text
32        departure_info.append(departure_time + ' ' + departure_airport
    )
33
34
35        return_time = flight.find_all('div',  {"class" :
    departure_info_regex})[2].find('time').text
36        return_airport = flight.find_all('div',  {"class" :
    departure_info_regex})[2].find('div').text
```

```
37          return_info.append(return_time + ' ' + return_airport)
38
39          nights.append(nights_spent)
40          prices.append(flight.find('strong',  {"data-test" : '
        ResultCardPrice'}).text)
41
42
43      df_flights = pd.DataFrame({'Departure date': departure_dates, '
        Departure info': departure_info, 'Return date': return_dates, '
        Return info': return_info, 'Nights' : nights, 'Prices': prices})
44      df_flights.to_csv('flights-belgrade-malaga-results.csv', index=
        False)
```

Оно што треба приметити јесте да се блок са информацијама о одласку са Веб сајта идентификовао коришћењем поклапања по регексу (енг. regex).

Проблем прикупљања података са више страница

TODO: уколико буде превише страница, ова секција се може обрисати јер се пример морао радити коришћењем другог сајта.

У претходно наведеном примеру су вађени подаци из ХТМЛ-а једне Веб странице. Такође је могуће динамично преузети податке и то ће се приказати на примеру Веб страница које не зависе од Јаваскрипта, коришћењем BeautifulSoap и requests пакета. У питању је Веб страница која садржи транскрипте филмова. Да би се успешно извршило преузимање података кроз више страница, треба да се разуме на који је начин то постигнуто на конкретном Веб сајту.

На веб адреси `https://subslikescript.com/movies_letter-A` уколико се изврши навигација на следећу страницу, може да се примети да се додаје и мења параметар *страница* (енг. page) у веб адреси и онда она изгледа овако `https://subslikescript.com/movies_letter-A?page=2`. Наведени код ниже са претходно стеченим знањем, проналази блок са нумерацијом страница, извлачи укупан број страница, пролази кроз сваку од њих, поставља вредност изворног ХТМЛ-а на нову тако што креира нову Веб адресу и уз помоћ requests пакета извлачи ХТМЛ нове странице, креира нови *BeautifulSoap* објекат за парсирање, проналази све линкове ка филмовима на датој страници, прелази на конкретан линк и преузима транскрипт филма. Кључни моменат јесте да се сваки пут иницијализује *BeautifulSoap* објекат за парсирање.

```
1  import requests
2  from bs4 import BeautifulSoup
3
4  root = 'https://subslikescript.com'
5  website = f'{root}/movies_letter-A'
6  result = requests.get(website)
7  content = result.text
8  soup = BeautifulSoup(content, 'lxml')
9
10 # pagination
11 pagination = soup.find('ul', class_='pagination')
12 pages = pagination.find_all('li', class_='page-item')
13 last_page = pages[-2].text
14
15 links = []
16
17 for page in range(1, int(last_page) + 1):
18     result = requests.get(f'{website}?page={page}')
19     content = result.text
20     soup = BeautifulSoup(content, 'lxml')
21
22     box = soup.find('article', class_='main-article')
23
24     for link in box.find_all('a', href=True):
25         links.append(link['href'])
26
27     for link in links:
28         try:
29             result = requests.get(f'{root}/{link}')
30             content = result.text
31             soup = BeautifulSoup(content, 'lxml')
32             box = soup.find('article', class_='main-article')
33
34             title = box.find('h1').get_text()
35             transcript = box.find('div', class_='full-script').
       get_text(strip=True, separator=' ')
36
37             print(link)
38             with open(f'movies/{title}.txt', 'w') as file:
39                 file.write(transcript)
40
41         except:
```

```
42                print('Link not working')
```

3.2 Библиотека Selenium

TODO: Инсталација, сајтови покренути са JS, драјвери, лоцирање елемената, пагинација, имплицитно и експлицитно чекање, попуњавање формулара, логин, кретање између страница, скрејповање странице са бесконачним скролом, како променити корисничког агента и зашто

3.3 Библиотека Scrapy

TODO: Инсталација, scrapy шаблони, креирање паука, стругање са више линкова, стругање са више страница, стругање АПИ, попуњавање формулара, логин, како променити корисничког агента, најосновније потребне функције LUA програмског језика (неопходно за SPLASH), SPLASH, шта представља SPLASH, зашто је неопходан, како превазићи Captcha)

Глава 4

Анализа резултата

TODO: Поређење перформанси, дијаграм односа времена стругања сајта и коришћене библиотеке, како оценити добијене резултате, табела са поређеним карактеристикама коришћених библиотека, препоруке, смернице за унапређење коришћених технологија

Глава 5

Закључак

TODO:

Библиографија

[1] Python Software Foundation 2001-2023. html.parser — Simple HTML and XHTML parser. on-line at: `https://docs.python.org/3/library/html.parser.html`.

[2] 2023 Software Freedom Conservancy. Selenium. on-line at: `https://www.selenium.dev/documentation/`.

[3] Stefan Behnel Martijn Faassen. Parsing XML and HTML with lxml. on-line at: `https://lxml.de/parsing.html`.

[4] Ryan Mitchell. In *Web Scraping with Python*, 2015.

[5] A Kenneth Reitz P. Requests: HTTP for Humans. on-line at: `https://requests.readthedocs.io/en/latest/`.

[6] Leonard Richardson. Beautiful Soup Documentation, 2004-2023. on-line at: `https://www.crummy.com/software/BeautifulSoup/bs4/doc/`.

Биографија аутора

Зорана Гајић, рођена 04.11.1997 у Москви, где је ... TODO: